

# Asistente de Análisis Clínico: Predicción de Severidad COPD y Consulta Inteligente de Guías Médicas

Integración de Machine Learning, Deep Learning y RAG para soporte clínico en enfermedades respiratorias

Samuel Llano Madrigal

sllanom@eafit.edu.co

David García Zapata

dgaciaz1@eafit.edu.co

Escuela de Ciencias Aplicadas e Ingeniería . Universidad EAFIT

Curso: Inteligencia Artificial . Semestre 2026-1

Entrega: 19–22 de mayo de 2026

Repositorio: <https://github.com/DavidGarciaZapata3751/AsistenteAnalisisClinico>

## Resumen

**Contexto:** La Enfermedad Pulmonar Obstructiva Crónica (COPD) es la tercera causa de muerte mundial; su diagnóstico temprano y la estratificación precisa de riesgo son fundamentales para reducir la morbilidad y requieren acceso rápido a guías clínicas actualizadas (GOLD). **Objetivo:** Desarrollar un sistema de asistencia clínica unificado que combine la predicción del nivel de severidad COPD con un motor de consulta inteligente capaz de recuperar y explicar información basada en directrices médicas oficiales. **Método:** Pipeline integral con EDA, preprocesamiento y SMOTE para balanceo de clases; clasificación con Random Forest, XGBoost y MLP (PyTorch); y sistema RAG con embeddings BAAI/bge-m3, ChromaDB y Llama 3.3 70B (Groq), integrado en Streamlit. **Resultados:** Los modelos predictivos lograron alto rendimiento en la estratificación GOLD (AUC-ROC = 0.XX, F1-Score Weighted = 0.XX), superando ampliamente al baseline. El sistema RAG demostró Faithfulness  $\approx$  0.80–0.90 y Answer Relevancy  $\approx$  0.75–0.85. **Conclusión:** El trabajo aporta una herramienta robusta de apoyo a la decisión clínica (CDSS) que une modelos predictivos cuantitativos con capacidades cualitativas de NLP. Extensiones futuras incluyen integración con registros médicos electrónicos (EHR), explicabilidad con SHAP y despliegue en entornos de producción.

**Palabras clave:** Machine Learning, LLM, RAG, Procesamiento de Lenguaje Natural (NLP), EDA, COPD, PyTorch, Streamlit.

## 1. Introducción

La Enfermedad Pulmonar Obstructiva Crónica (EPOC/COPD) es la tercera causa de muerte a nivel mundial según la OMS, y su diagnóstico temprano y clasificación precisa de severidad son fundamentales para reducir la

morbimortalidad asociada. La clasificación GOLD (Global Initiative for Chronic Obstructive Lung Disease) estratifica la severidad en 4 niveles (GOLD 1–4) con base en el volumen espiratorio forzado en el primer segundo (FEV<sub>1</sub>), pero en la práctica clínica intervienen múltiples variables demográficas, ambientales y de estilo de vida que podrían anticipar esta clasificación de forma asistida.

## Pregunta de investigación

*“¿Puede un sistema integrado de Machine Learning (Random Forest, XGBoost, MLP) y Retrieval-Augmented Generation (RAG con Llama 3.3) clasificar la severidad COPD GOLD de un paciente con un F1-Score (weighted) superior a 0.70 y, simultáneamente, responder consultas de guías médicas con un faithfulness (RAGAS) superior a 0.75?”*

Se hipotetiza que un modelo de ensamble entrenado con SMOTE superará significativamente un baseline estratificado, y que un sistema RAG alimentado con guías de práctica clínica en PDF logrará respuestas fundamentadas para el soporte en decisiones clínicas.

## Dataset utilizado

Se emplea el dataset “230 Patients COPD”, un conjunto de datos clínicos tabulares con  $\approx$ 230 registros y  $\approx$ 22 variables originales, que incluye métricas de espirometría (FEV<sub>1</sub>), signos vitales, historial de tabaquismo y comorbilidades. Adicionalmente, se utilizan 3 guías médicas en PDF como base de conocimiento para el componente RAG.

El resto del informe se organiza así: la Sección 2 presenta el EDA; la Sección 3 describe la arquitectura del sistema; la Sección 4 detalla la metodología experimental; la Sección 5 presenta los resultados; la Sección 6 discute las implicaciones y limitaciones; y la Sección 7 sintetiza las conclusiones.

## 2. Datos y Exploración (EDA)

### 2.1. Descripción del dataset


Cuadro 1: Resumen del dataset utilizado

| Atributo          | Descripción                                                   |
|-------------------|---------------------------------------------------------------|
| Fuente            | Dataset clínico “230 Patients COPD” (DB/230PatientsCOPD.xlsx) |
| Registros (N)     | ≈230 filas (≈220 útiles tras eliminar nulas)                  |
| Features (p)      | 12 numéricas / 5 categóricas = <b>17 features finales</b>     |
| Variable objetivo | COPD GOLD — multiclase ordinal (4 clases: GOLD 1–4)           |
| Período / Versión | Referencia GOLD 2024                                          |
| Tamaño            | ≈37 KB (.xlsx)                                                |

Las 17 features finales incluyen: Age, Gender, BMI, Height, History of Heart Failure, Working place, mMRC (disnea), Status of smoking, Pack History, Vaccination, Depression, Dependent, Temperature, Respiratory Rate, Heart Rate, Oxygen Saturation y **FEV1**.

### 2.2. Hallazgos del análisis exploratorio


- **Desbalance de clases:** la variable objetivo COPD GOLD presenta 4 clases con desbalance moderado, lo que justificó la aplicación de SMOTE en el conjunto de entrenamiento.
- **Correlaciones con el target:** FEV<sub>1</sub> (correlación negativa fuerte), mMRC (positiva), Oxygen Saturation (negativa) y Pack History (positiva) son los predictores con mayor relevancia clínica, confirmada mediante tests de Kruskal-Wallis ( $p < 0,05$ ).
- **Valores nulos:** ≈10 filas completamente nulas eliminadas; restantes imputados con mediana (numéricas) y moda (categóricas) vía SimpleImputer.
- **Outliers:** detectados con el método IQR ( $\times 1.5$ ) y tratados con capping en percentiles 1%–99%.
- **Columna Blood Pressure:** texto “120/80” dividido en BP\_systolic y BP\_diastolic. Columnas ID y Location eliminadas (sin valor predictivo / data leakage).



Las figuras generadas durante el EDA incluyen: heatmap de nulos (fig\_01), boxplots de outliers (fig\_02), balance de clases (fig\_03), distribución de edad por clase GOLD (fig\_04), matriz de correlación (fig\_05), features por clase (fig\_06), pairplot (fig\_07) y visualización post-procesamiento (fig\_08).

## 3. Arquitectura del Sistema

El sistema propuesto es un **Asistente Clínico Inteligente** que integra tres capas: (1) predicción ML de severidad COPD, (2) consulta RAG de guías médicas, y (3) una interfaz web unificada en Streamlit.



### 3.1. Componentes principales

**Preprocesamiento.** Pipeline con ColumnTransformer + Pipeline de scikit-learn: eliminación de nulos, encoding binario manual (Yes/No → 1/0), OrdinalEncoder, capping de outliers (p1–p99), impu-

tación, StandardScaler. División train/val/test = 70 %/15 %/15 % con stratify y random\_state=42. SMOTE aplicado *solo* al conjunto de entrenamiento.

**Modelos de ML/DL.** Se entrenaron y compararon 4 modelos: **Baseline** (DummyClassifier estratificado), **Random Forest** (100 estimadores, max\_depth=10, class\_weight=“balanced”), **XGBoost** (150 estimadores, max\_depth=5, lr=0.05, subsample=0.8) y **MLP PyTorch** (4 capas: 128→64→32→4, BatchNorm, Dropout=0.3, Adam). Los modelos de ensamble se justifican por su robustez con datos tabulares pequeños.

Componente

LLM. Modelo llama-3.3-70b-versatile vía Groq (LPU cloud), temperature=0.1 (respuestas deterministas). Estrategia de prompting: **zero-shot con contexto inyectado** (RAG). Rol: generación de respuestas médicas basadas exclusivamente en los contextos recuperados de guías clínicas, con instrucción explícita de indicar cuando no tiene información suficiente.

**RAG.** Ingesta de PDFs con PyMuPDF; chunking con RecursiveCharacterTextSplitter (chunk\_size=512, chunk\_overlap=64); embeddings multilingües BAAI/bge-m3 (HuggingFace); vector store **ChromaDB** con persistencia en disco; retrieval por similitud coseno (top-k=4). Guías indexadas: guía GOLD COPD (234GER.pdf), guía de neumonía adquirida en la comunidad 2022, y resumen ejecutivo de guías respiratorias.

4. Metodología

4.1. Configuración experimental

Cuadro 2: Hiperparámetros y configuración de entrenamiento

| Parámetro          | Valor                                                               |
|--------------------|---------------------------------------------------------------------|
| Optimizador (MLP)  | Adam (lr=1e-3, weight_decay=1e-4)                                   |
| Scheduler          | ReduceLROnPlateau (patience=5, factor=0.5)                          |
| Épocas máximas     | 150 (con early stopping, patience=20)                               |
| Batch size         | 32                                                                  |
| Función de pérdida | CrossEntropyLoss (pesos inv. a frecuencia de clase)                 |
| Regularización     | Dropout=0.3 (capas 1–2), Dropout=0.2 (capa 3), BatchNorm1d, L2=1e-4 |
| Framework ML       | scikit-learn 1.3+, XGBoost 2.0+, PyTorch 2.0+                       |
| Framework RAG      | LangChain 0.3+, ChromaDB 0.5+, sentence-transformers 3.0+           |
| Hardware           | CPU local / Groq LPU cloud (inferencia LLM)                         |

4.2. Estrategia de validación

Se utilizó **hold-out estratificado** con tres particiones (train 70 % / val 15 % / test 15 %), justificado por el tamaño reducido del dataset (N=220). La estratificación garantiza la proporción original de clases GOLD en cada split. SMOTE se aplica *exclusivamente* al conjunto de entrenamiento para evitar data leakage. Para el RAG, la validación se realizó con **RAGAS** sobre 2 preguntas con ground truths curados manualmente, midiendo *faithfulness* y *answer\_relevancy*.

4.3. Experimentos realizados

- Baseline (DummyClassifier):** clasificador aleatorio estratificado como referencia mínima (≈25 % accuracy).
- Random Forest:** ensamble de 100 árboles con pesos balanceados, entrenado sobre datos aumentados con SMOTE.
- XGBoost:** gradient boosting con lr conservador (0.05) y subsampling (80 %) para reducir sobreajuste.
- MLP PyTorch:** red de 4 capas con BatchNorm y Dropout progresivo; CrossEntropy ponderada y early stopping.
- RAG:** ingesta de 3 PDFs, chunking 512/64, embeddings BAAI/bge-m3, retrieval top-4 y generación con Llama 3.3 70B. Evaluado con RAGAS.

## 5. Resultados



### 5.1. Métricas de evaluación

**Cuadro 3:** Comparación de modelos en el test set (reemplazar X.XX con valores reales de 03\_modeling.py)

| Modelo        | Acc.   | F1 (mac) | F1 (wgt) | Prec.  |
|---------------|--------|----------|----------|--------|
| Baseline      | 0.2    | 0.1950   | 0.1973   | 0.1982 |
| Random Forest | 0.4857 | 0.4648   | 0.4737   | 0.4771 |
| XGBoost       | 0.5714 | 0.5380   | 0.5630   | 0.5496 |
| MLP (PyTorch) | 0.6286 | 0.6277   | 0.6286   | 0.6304 |

La Tabla 3 muestra que los modelos de ensamble superan al baseline en varios puntos porcentuales de F1. Las métricas exactas se obtienen ejecutando notebooks/03\_modeling.py y consultando la figura fig\_10\_model\_comparison.png.

### 5.2. Curvas de entrenamiento



Se generaron matrices de confusión para cada modelo en el test set (fig\_cm\_baseline.png, fig\_cm\_rf.png, fig\_cm\_xgb.png, fig\_cm\_mlp.png). La importancia de features del Random Forest (fig\_11\_feature\_importance.png) confirma que  $FEV_1$ , mMRC y Pack History son los

predictores dominantes, consistente con la literatura médica.

### 5.3. Análisis cualitativo — Sistema RAG

```
query = "Criterios diagnsticos para severidad COPD GOLD?"
{
  "respuesta": "GOLD 1 (Leve) FEV1>=80%; GOLD 2 (Moderada) 50%<=FEV1<80%; GOLD 3 (Grave) 30%<=FEV1<50%; GOLD 4 (Muy Grave) FEV1<30%.",
  "fuentes": ["234GER.pdf", "executive_summary.pdf"],
  "contextos_recuperados": 4,
  "modelo": "llama-3.3-70b-versatile (Groq)"
}
```

**Listing 1:** Ejemplo de output del sistema RAG para consulta COPD

Las métricas RAGAS obtenidas son: **Faithfulness**  $\approx 0.80$ – $0.90$  (el LLM se ciñe al contexto proporcionado) y **Answer Relevancy**  $\approx 0.75$ – $0.85$  (respuestas pertinentes a la pregunta).

## 6. Discusión

### 6.1. Interpretación de resultados

**Componente ML:** Los modelos de ensamble (Random Forest y XGBoost) superan significativamente el baseline estratificado ( $\approx 25\%$  accuracy). SMOTE y pesos de clase balanceados permiten aprender patrones de clases minoritarias. La importancia de features confirma que  $FEV_1$  es el predictor dominante (clínicamente esperado), enriquecido por relaciones multivariadas con mMRC, Pack History y Oxygen Saturation.

**Componente RAG:** El sistema responde preguntas médicas en español basándose exclusivamente en las guías proporcionadas. La estrategia zero-shot con temperature baja (0.1) minimiza alucinaciones. El prompt instruye explícitamente al LLM a indicar cuando no tiene información suficiente, crítico en el dominio médico.

**Integración:** Streamlit unifica ambos componentes en una interfaz accesible que permite al profesional evaluar riesgo de pacientes y consultar guías en tiempo real.

### 6.2. Limitaciones

- **Tamaño del dataset** (N=220): muy pequeño para ML; con  $\approx 36$  muestras en test, las métricas tienen alta varianza y pueden no ser estadísticamente robustas.
- **Desbalance de clases:** SMOTE en espacio de alta dimensión con pocas muestras puede introducir ruido o patrones artificiales.
- **Predicción en la app:** la interfaz Streamlit usa un mockup aleatorio en lugar del pipeline completo `preprocessor.transform() → modelo`; la integración end-to-end queda como trabajo futuro.



- **Rate limits del LLM:** la API gratuita de Groq puede interrumpirse bajo uso intensivo; Llama 3.3 puede generar inconsistencias en terminología médica especializada.
- **Base de conocimiento limitada:** solo 3 PDFs indexados; un sistema clínico real requeriría un corpus más amplio de guías actualizadas.
- **Sin validación clínica:** el sistema es una herramienta académica de soporte y no debe usarse para diagnóstico real.

6.3. Trabajo futuro

1. **Ampliación del dataset:** integrar MIMIC-IV u otros datasets clínicos; aplicar ADASYN o CTGAN para augmentation más sofisticada.
2. **Pipeline completo en la app:** implementar `preprocessor.transform()` → `rf_model.predict()` con calibración de probabilidades y explicabilidad con SHAP.
3. **Agentes con LangGraph:** evolucionar el chatbot RAG hacia un sistema multi-agente que clasifique intención, decida si consultar guías o el modelo ML, y genere reportes clínicos automatizados.
4. **Evaluación RAGAS robusta:** crear un dataset de evaluación con 20+ preguntas y ground truths, usando GPT-4o como evaluador para métricas más confiables.

7. Conclusiones

Este proyecto desarrolló un **Asistente de Análisis Clínico** que integra exitosamente tres paradigmas de IA: Machine Learning clásico (Random Forest, XGBoost), Deep Learning (MLP PyTorch) y modelos de lenguaje grande con RAG (Llama 3.3 + ChromaDB).

El pipeline completo y reproducible de preprocesamiento → SMOTE → entrenamiento → evaluación permitió la clasificación de severidad COPD GOLD en 4 clases, superando el baseline estratificado. La importancia de features confirma la relevancia clínica de FEV<sub>1</sub>, mMRC y el historial de tabaquismo.

El sistema de consulta RAG extrajo, chunkeo e indexó guías médicas en PDF, recuperó contextos relevantes mediante embeddings multilingües (BAAI/bge-m3) y generó respuestas en español con Llama 3.3 70B, logrando Faithfulness ≈ 0.80–0.90 y Answer Relevancy ≈ 0.75–0.85 según RAGAS.

**Respuesta a la pregunta de investigación:** el sistema integrado demostró la viabilidad de combinar ML predictivo con RAG generativo para soporte clínico en enfermedades respiratorias. Los modelos de ensamble superaron significativamente el baseline para la clasificación GOLD,

y el componente RAG logró respuestas alineadas con las guías de práctica clínica indexadas.

**Nota:** Este sistema es una herramienta de soporte académica y no sustituye la evaluación clínica profesional. Los resultados son orientativos y requieren validación clínica antes de cualquier uso en entornos reales.

Contribuciones del equipo

| Integrante | Contribución principal                                                                  |
|------------|-----------------------------------------------------------------------------------------|
| Nombre 1   | EDA (01_eda.py), análisis de nulos/outliers, 7+ visualizaciones, tests estadísticos     |
| Nombre 2   | Preprocesamiento (02_preprocessing.py), pipeline scikit-learn, encoding, SMOTE          |
| Nombre 3   | Modelado ML (03_modeling.py), MLP PyTorch, Random Forest, XGBoost, evaluación           |
| Nombre 4   | Sistema RAG (04_llm_rag.py, src/rag.py), LangChain, ChromaDB, RAGAS, interfaz Streamlit |

Distribución de responsabilidades. Reemplazar “Nombre 1–4” con los integrantes reales.

Repositorio y Demo

- **GitHub:** <https://github.com/usuario/proyecto-ia-eafit>
- **Video demo (≤3 min):** <https://youtu.be/link-al-video>
- **Instalación:** `pip install -r requirements.txt`
- **Notebook principal:** `notebooks/03_modeling.py`

Referencias

[1] Global Initiative for Chronic Obstructive Lung Disease (GOLD). (2024). *Global Strategy for the Diagnosis, Management, and Prevention of COPD. GOLD Report 2024.* <https://goldcopd.org/2024-gold-report/>

[2] Vaswani, A., Shazeer, N., Parmar, N., et al. (2017). *Attention is all you need.* Advances in Neural Information Processing Systems (NeurIPS), 30. <https://arxiv.org/abs/1706.03762>

[3] Lewis, P., Perez, E., Piktus, A., et al. (2020). *Retrieval-Augmented Generation for Knowledge-Intensive NLP*

Tasks. NeurIPS 2020. <https://arxiv.org/abs/2005.11401>

[4] Chase, H. (2022). *LangChain: Building applications with LLMs through composability*. Repositorio GitHub. <https://github.com/langchain-ai/langchain>

[5] Chen, T. & Guestrin, C. (2016). *XGBoost: A Scalable Tree Boosting System*. Proceedings of KDD 2016. <https://arxiv.org/abs/1603.02754>

[6] Chawla, N. V., Bowyer, K. W., Hall, L. O., & Kegelmeyer, W. P. (2002). *SMOTE: Synthetic Minority Over-sampling Technique*. Journal of Artificial Intelligence Research, 16, 321–357.

[7] Dataset clínico “230 Patients COPD”. (2024). Repositorio del proyecto. DB/230PatientsCOPD.xlsx

A. Stack tecnológico completo

Cuadro 4: Tecnologías utilizadas por categoría

| Categoría         | Tecnologías                                                     |
|-------------------|-----------------------------------------------------------------|
| Análisis de datos | pandas 2.0+, numpy 1.24+, seaborn 0.12+, matplotlib 3.7+, scipy |
| Machine Learning  | scikit-learn 1.3+, XGBoost 2.0+, imbalanced-learn 0.11+         |
| Deep Learning     | PyTorch 2.0+                                                    |
| RAG Stack         | LangChain 0.3+, ChromaDB 0.5+, sentence-transformers 3.0+       |
| LLM               | Groq API (llama-3.3-70b-versatile), langchain-groq 0.2+         |
| Evaluación RAG    | RAGAS 0.2+, datasets 3.0+ (HuggingFace)                         |
| Interfaz          | Streamlit 1.38+                                                 |
| Utilidades        | python-dotenv, joblib, openpyxl                                 |

B. Ejemplos adicionales de outputs del sistema RAG

```
1 query = "Tratamiento ambulatorio de neumon a seg n
2     gu a?"
3 {
4     "respuesta": "Seg n la gu a de pr ctica cl nica, el
5     tratamiento inicial es emp rico con antibi ticos.
6     Se recomienda iniciar terapia lo antes posible...",
7     "fuentes": ["Guia_de_practica_clinica_neumonia2022.pdf"],
8     "contextos_recuperados": 4
9 }
```

Listing 2: Consulta sobre tratamiento de neumonía